

# Modul 4: Tests und Inferenz

PI 6250 – Ökonometrie I

Max Heinze ([mheinze@wu.ac.at](mailto:mheinze@wu.ac.at))

Department für Volkswirtschaftslehre, WU  
Wien

8. Mai 2025

# Einführung

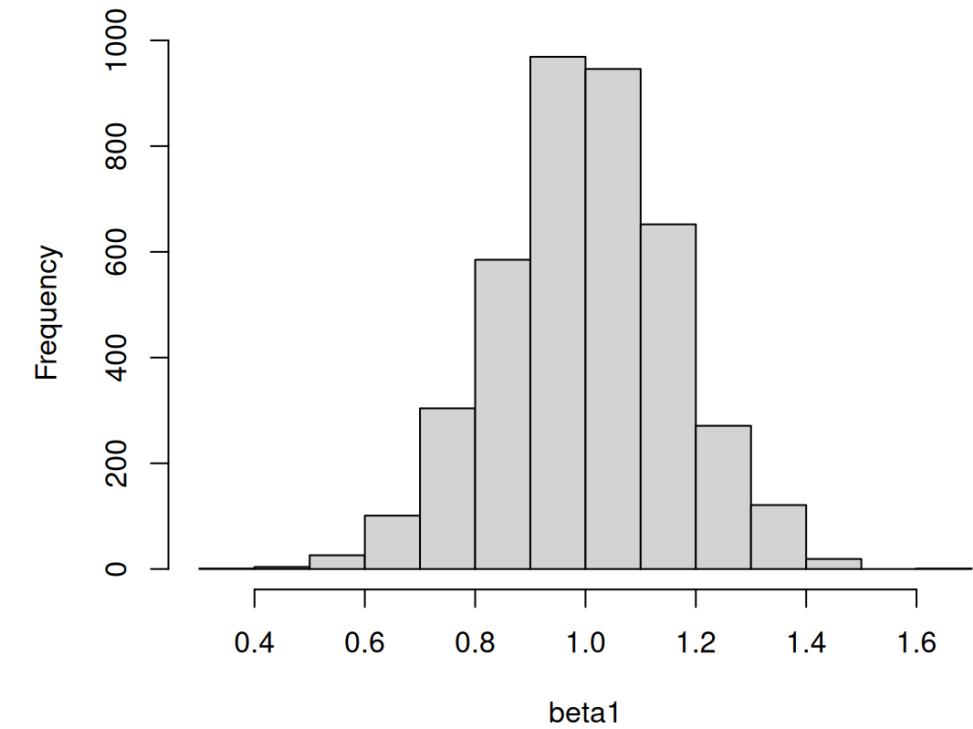
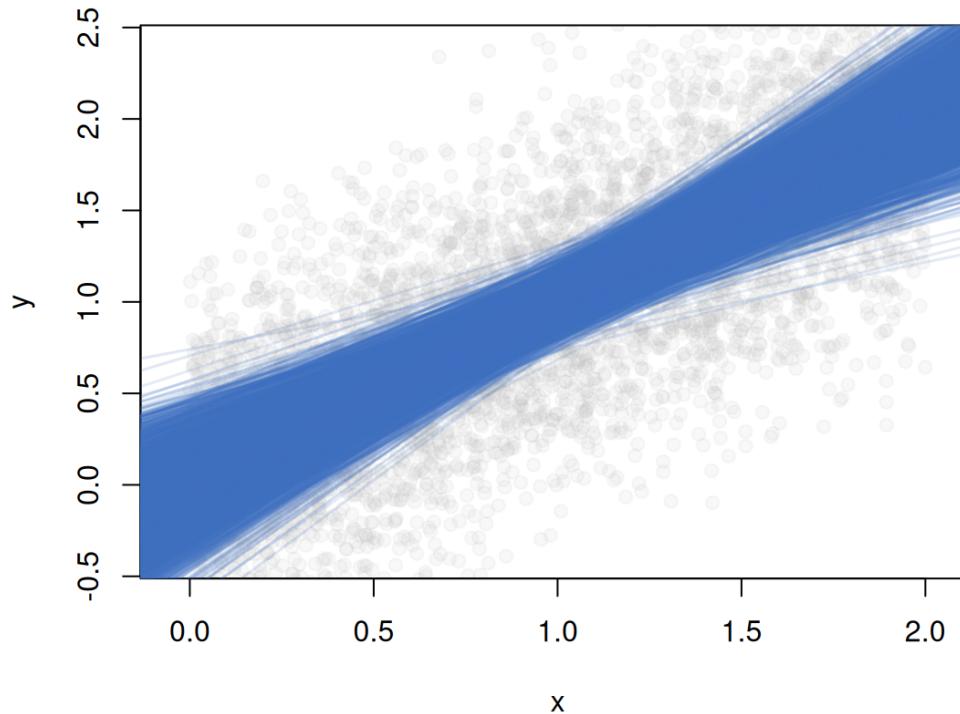
Kleine Stichproben

t-Test

F-Test

# Motivation

In **Modul 2** (und 3) haben wir näher betrachtet, was es heißt, dass unser OLS-Schätzer eine **Zufallsvariable** ist. Wir haben **Erwartungswert** und **Varianz** des Schätzers bestimmt und auch folgende Simulation durchgeführt:



# Motivation

Für alles, was wir in diesem Kapitel besprechen, brauchen wir aber mehr als nur die beiden Momente Erwartungswert und Varianz. Wir müssen uns fragen: **Was ist die Stichprobenverteilung des OLS-Schätzers?**

Wofür brauchen wir Information über diese Verteilung? In **Modul 1** haben wir gesagt:

Um eine **Hypothese** mit **Daten** überprüfen zu können, brauchen wir **Daten** und eine **Hypothese**.

- Idealerweise haben wir eine **Theorie**, aus der wir eine **falsifizierbare Hypothese** ableiten können.
- Dann können wir versuchen, diese **Hypothese** empirisch zu **testen**.

# Hypothesentests

Aber wie **testen** wir eine **Hypothese**? Angenommen, wir wollen wissen, ob der Parameter  $\beta_1$  ungleich Null ist, also ob die entsprechende Variable  $x_1$  einen Effekt auf  $y$  hat.

- **Erste Idee:** Wir schätzen unser Modell mit OLS und schauen, ob der Absolutbetrag der Schätzung  $|\hat{\beta}_1| > 0$  ist.
  - Diese **Idee** ist eine **schlechte Idee**.
  - **Intuition:** Wir wissen, dass wir eine gewisse **Unsicherheit** in unserer Schätzung haben. Wenn unsere Schätzung z.B. nahe bei Null ist und/oder die Unsicherheit groß ist – wie „sicher“ können wir uns da sein, dass unsere Schätzung nicht rein zufällig nicht Null ist?
- **Bessere Idee:** Wir **nehmen an**, dass das wahre  $\beta_1$  **gleich Null** ist und versuchen herauszufinden, was die **Wahrscheinlichkeit** ist, dass wir **dann trotzdem die Schätzung bekommen**, die wir erhalten haben.
  - Wenn diese Wahrscheinlichkeit klein ist, können wir sagen, dass es **unwahrscheinlich** ist, so eine Schätzung zu erhalten, **wenn** der wahre Parameter  $\beta_1 = 0$  ist.

# Hypothesentests

Das, was wir auf der vorherigen Folie besprochen haben, nennen wir einen **Hypothesentest** (engl. **hypothesis test**). Etwas formeller:

- (1) Wir stellen eine sogenannte **Nullhypothese** (engl. **null hypothesis** oder kurz **null**) auf:

$$H_0 : \beta_1 = 0.$$

Daraus ergibt sich auch eine Alternativhypothese:

$$H_A : \beta_1 \neq 0.$$

- (2) Wir nehmen an, dass die **Nullhypothese stimmt**, und berechnen, was in diesem Fall die Wahrscheinlichkeit ist, **die Schätzung  $\hat{\beta}_1$  zu erhalten**.
- (3) Wenn diese Wahrscheinlichkeit **ausreichend gering** ist, **verwerfen** wir die **Nullhypothese**.

# Null- und Alternativhypothese

Warum ist unsere Nullhypothese  $\beta_1 = 0$  und nicht  $\beta_1 \neq 0$ ?

- Einerseits erlauben uns klassische statistische Tests nur, zu **testen, ob  $\beta_0$  ein bestimmter Wert ist**, zum Beispiel 0.
  - Wir haben gesagt, wir nehmen an, die Nullhypothese stimmt, und berechnen dann die Wahrscheinlichkeit, ein bestimmtes  $\hat{\beta}_1$  unter dieser Nullhypothese zu erhalten.
  - Wenn die Nullhypothese  $\beta_1 = 0$  ist, dann ist das sinnvoll und intuitiv zu verstehen. Wenn  $\beta_1 = 0$ , dann ist es wahrscheinlicher,  $\hat{\beta}_1 = 1$  zu erhalten, als  $\hat{\beta}_1 = 5$ .
  - Würden wir als Nullhypothese  $\beta_1 \neq 0$  haben, wäre das gar nicht möglich. Die besprochene Wahrscheinlichkeit wäre völlig anders für  $\beta_1 = 12$ ,  $\beta_1 = 0.00000001$  und  $\beta_1 = -10^6$ .

# Verwerfen heißt nicht das Gegenteil bestätigen

Warum ist unsere Nullhypothese  $\beta_1 = 0$  und nicht  $\beta_1 \neq 0$ ?

- Außerdem können wir mithilfe statistischer Tests **eine Hypothese nie bestätigen**, sondern **nur verwerfen** (engl. **reject a hypothesis**).
  - Wir wollen herausfinden, ob  $x_1$  einen Einfluss auf  $y$  hat.
  - Wenn unsere **Nullhypothese** ist, dass sie **keinen Einfluss** hat ( $\beta_1 = 0$ ), dann gibt uns die **Verwerfung dieser Hypothese** einen wichtigen Hinweis in die Richtung, dass die Variable Einfluss hat.
  - Wir können aber **nie bestätigen**, dass eine Variable Einfluss hat, wir können nur die Hypothese **verwerfen**, dass sie keinen Einfluss hat.
  - Das liegt daran, dass wir uns beim Verwerfen einer Hypothese mit einer **ausreichend geringen Wahrscheinlichkeit** begnügen, diese Wahrscheinlichkeit aber nie 0 ist.

Auf jeden Fall brauchen wir für dieses Testprocedere **Informationen über die Stichprobenverteilung von  $\hat{\beta}_1$** , also beschäftigen wir uns erst einmal damit, bevor wir zu Hypothesentests zurückkehren.

# Einführung

# Kleine Stichproben

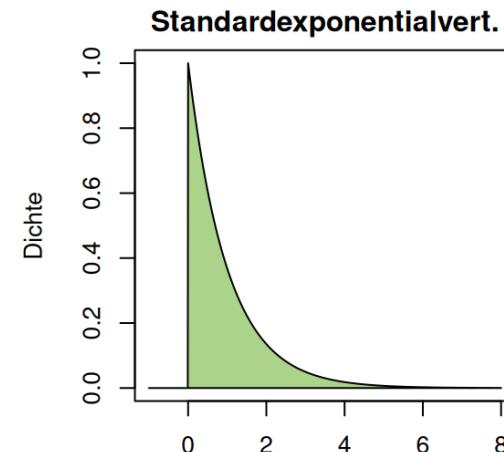
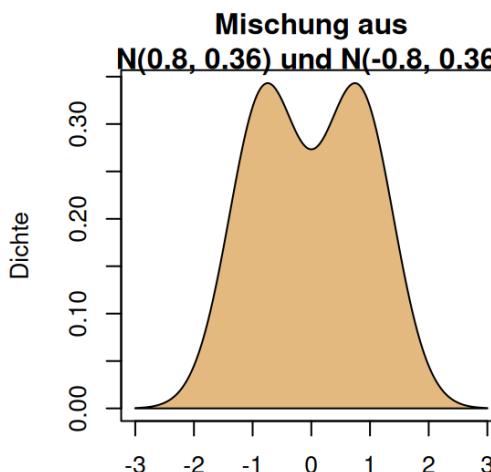
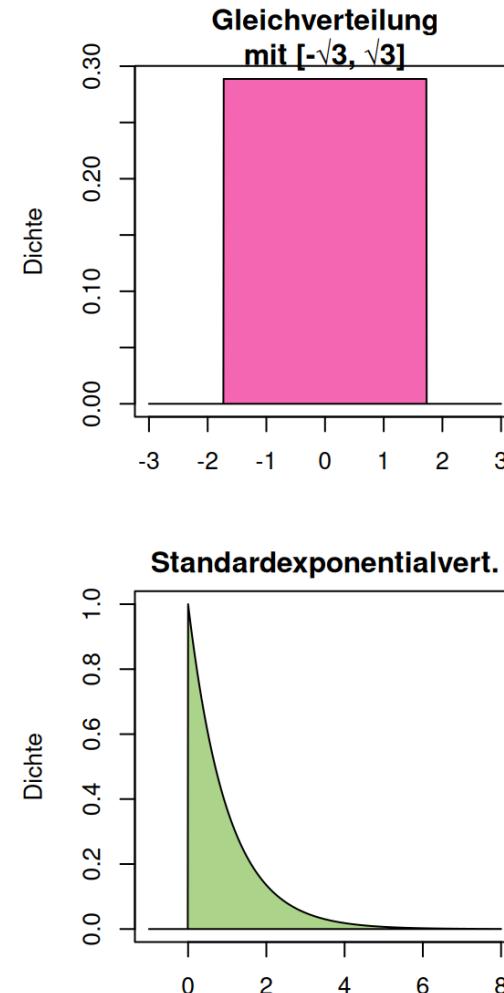
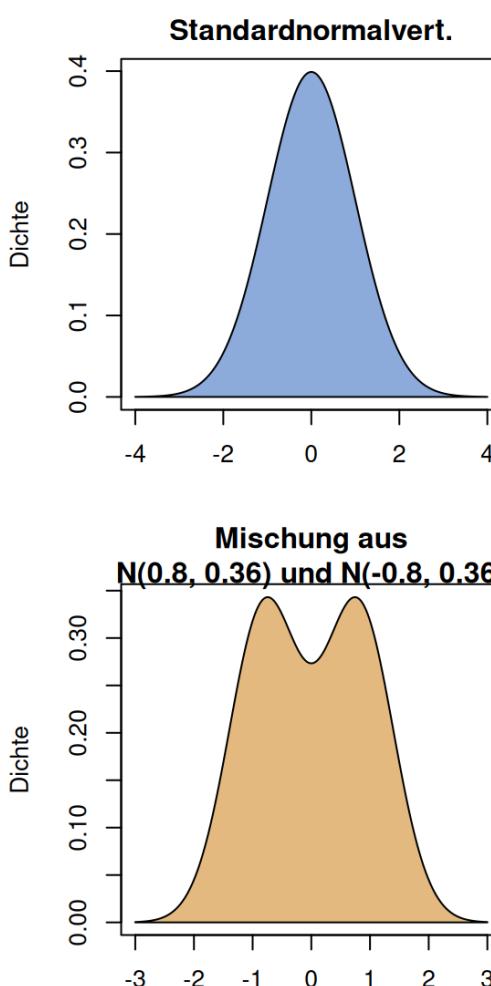
## t-Test

## F-Test

## Interpretation von Regressionstabellen

# Momente vs. Verteilung

Wir haben mithilfe der **Annahmen MLR.1 bis MLR.5** Aussagen über den Erwartungswert und die Varianz des OLS-Schätzers treffen können.



- Das reicht uns aber nicht, um Aussagen über die **Verteilung** zu treffen.
- Ein Beispiel: Die vier Verteilungen links haben alle einen Erwartungswert von 0 und eine Varianz von 1.
- Auch unter den **Gauß-Markov-Annahmen** kann die Verteilung von  $\hat{\beta}_1$  sehr verschiedene Formen annehmen.
- Wir benötigen daher eine **weitere Annahme**.

## (MLR.6) Normalität

Der Fehlerterm der Grundgesamtheit ist unabhängig von den erklärenden Variablen  $x_1, \dots, x_K$  und ist normalverteilt mit Erwartungswert 0 und Varianz  $\sigma^2$ :

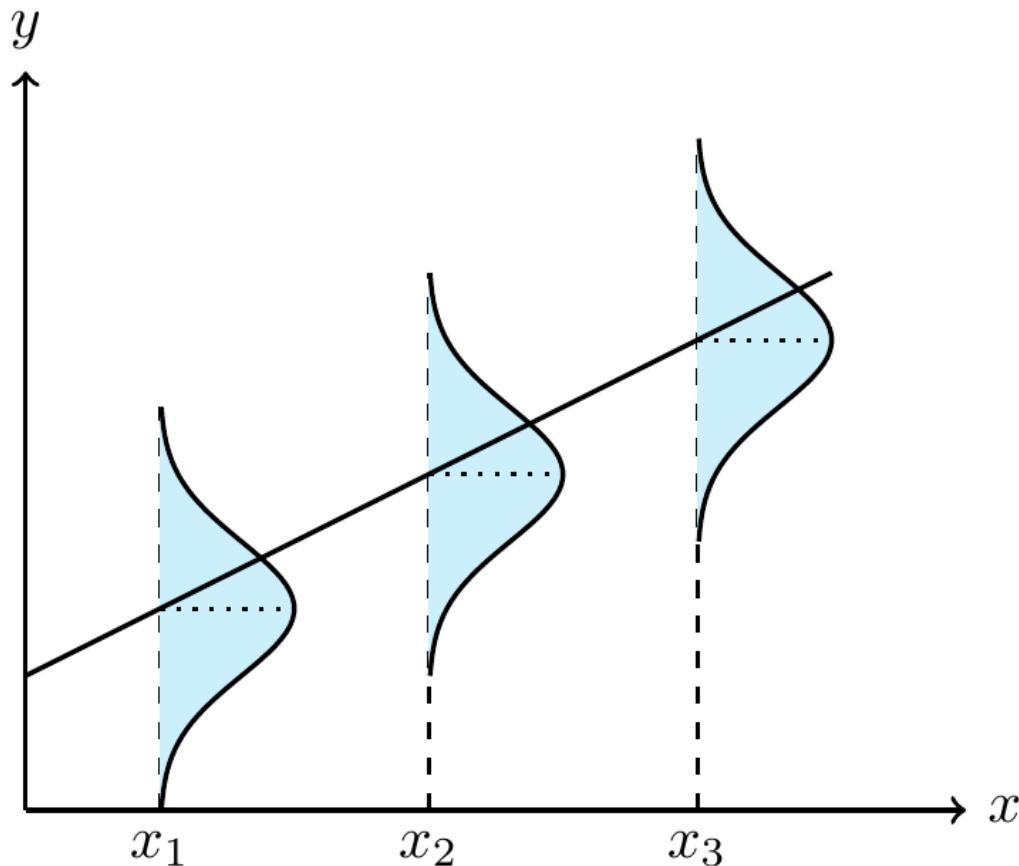
$$u \sim N(0, \sigma^2)$$

- Diese Annahme impliziert die Annahmen MLR.4 und MLR.5. Wir sprechen trotzdem von MLR.1 bis MLR.6, um zu verdeutlichen, dass wir MLR.6 „zusätzlich“ annehmen.
- Diese Annahme ist eine **extrem starke Annahme**. Mehr dazu gleich.
- Wir nennen MLR.1 bis MLR.6 zusammen auch **Classical-Linear-Model-Annahmen (CLM-Annahmen)**.
- Unter den CLM-Annahmen ist OLS nicht nur BLUE, sondern **BUE** (nicht auf lineare Schätzer beschränkt).

## (MLR.6) Normalität

Wir können die CLM-Annahmen bezüglich der Grundgesamtheit so zusammenfassen:

$$y \mid \boldsymbol{x} \sim N(\boldsymbol{x}'\boldsymbol{\beta}, \sigma^2).$$



- Die Grafik links illustriert diesen Fakt für den **bivariaten Fall** (die Subskripte sind also  $i$ , nicht  $k$ ).
- Unter den CLM-Annahmen sind die  $y$  für eine Beobachtung  $i$  normalverteilt mit
  - Mittelwert  $\boldsymbol{x}'\boldsymbol{\beta}$  (im bivariaten Fall links  $\beta_1x$ ) und
  - immer der gleichen Varianz  $\sigma^2$ .

# Macht MLR.6 Sinn?

- Wie vorher erwähnt, ist  $u \sim N(0, \sigma^2)$  eine sehr **starke Annahme**. Können wir diese Annahme rechtfertigen?
- Ein Argument: Der Fehlerterm  $u$  ist eine **Summe aus vielen unbeobachteten Faktoren**, die  $y$  beeinflussen. Daher kann der **zentrale Grenzwertsatz** (nächste Folie) angewendet werden und  $u$  ist **annähernd normalverteilt**.
  - Allerdings können die verschiedenen Faktoren in  $u$  sehr **unterschiedliche Verteilungen** haben, was die Approximation verschlechtert.
  - Außerdem garantiert uns nichts, dass die einzelnen Faktoren **additiv** im Fehlerterm auftreten. Das ist noch ein wesentlich größeres Problem.
- Später besprechen wir, warum Nichtnormalität der Fehler **in größeren Stichproben** kein großes Problem darstellt. Bis auf weiteres nehmen wir einfach **Normalität** an.
  - Manchmal werden in kleineren Stichproben **Transformationen** (z.B. Logarithmieren) angewandt, damit die  $y$ -Werte näher an einer Normalverteilung liegen.

# Zentraler Grenzwertsatz / Central Limit Theorem

Der **Zentrale Grenzwertsatz** (engl. **central limit theorem, CLT**) besagt:

Sei  $\{X_1, X_2, \dots, X_N\}$  eine Folge von unabhängig und identisch verteilten Zufallsvariablen mit Mittelwert  $\mu$  und Varianz  $\sigma^2$ . Dann konvergiert die Verteilungsfunktion der standardisierten Zufallsvariable

$$Z_N = \frac{\bar{X}_N - \mu}{\sigma/\sqrt{N}},$$

wobei  $\bar{X}_N = \frac{1}{N} \sum_{i=1}^N X_i$ , in Verteilung gegen die Verteilungsfunktion der **Standardnormalverteilung**.

- $Z_n$  ist eine standardisierte Version des Stichprobenmittelwerts.
- Intuitiv: Wenn  $N$  größer wird, konvergiert die Verteilung des Mittelwerts der  $X_i$  gegen eine Normalverteilung.

# Verteilung des OLS-Schätzers, Teil 1

Unter den **CLM-Annahmen** MLR.1 bis MLR.6 ist der OLS-Schätzer, gegeben die Stichprobenwerte der unabhängigen Variablen normalverteilt:

$$\hat{\beta}_k \sim N(\beta_k, \text{Var}(\hat{\beta}_k)),$$

wobei  $\text{Var}(\hat{\beta}_k) = \frac{\sigma^2}{\sum_{i=1}^N (x_{ik} - \bar{x}_k)^2} \times \frac{1}{1-R_k^2}$ , wo wiederum  $R_k^2$  das  $R^2$  einer Regression von  $x_k$  auf alle anderen Regressoren  $x_j, j \neq k$  ist.

- $\hat{\beta}_k$  ist **normalverteilt**, jede Linearkombination der  $\hat{\beta}_k$  ist ebenso normalverteilt, und die gemeinsame Verteilung einer Teilmenge der  $\hat{\beta}_j$  ist eine multivariate Normalverteilung.
- Der **standardisierte Koeffizient**  $(\hat{\beta}_k - \beta_k)/\text{sd}(\hat{\beta}_k)$  ist standardnormalverteilt.

# Einführung Kleine Stichproben

**t-Test**

**F-Test**

**Interpretation von Regressionstabellen**  
**Große Stichproben**

# Hypothesen über den OLS-Schätzer

Wir beschäftigen uns in diesem Abschnitt damit, **Hypothesen über einen der Parameter** des Populations-Modells

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_K x_K + u$$

zu testen.

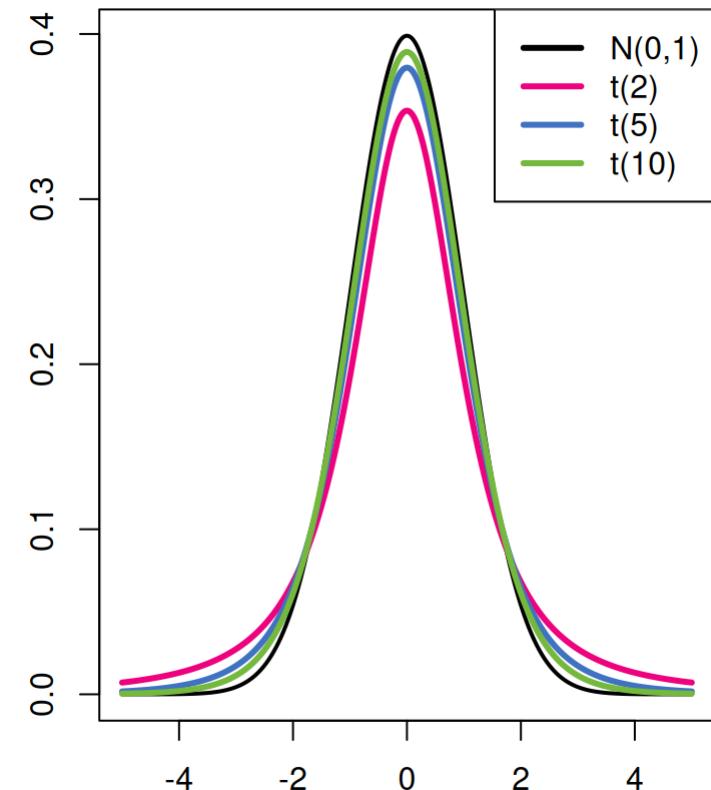
- Nach wie vor gilt: Wir kennen die  $\beta_k$  nicht. Wir können sie nur schätzen.
- Aber wir können **Hypothesen** über die  $\beta_k$  anstellen.
- Im nächsten Schritt können wir statistische Inferenz benutzen, um diese **Hypothesen zu testen**.

# Verteilung des OLS-Schätzers, Teil 2

Unter den **CLM-Annahmen** MLR.1 bis MLR.6 gilt:

$$(\hat{\beta}_k - \beta_k) / \text{se}(\hat{\beta}_k) \sim t_{N-K-1}$$

- Wenn wir im standardisierten Koeffizienten  $\text{sd}(\cdot)$  durch  $\text{se}(\cdot)$  (also  $\sigma$  durch  $\hat{\sigma}$ ) ersetzen, ist er nicht mehr standardnormalverteilt, sondern folgt einer **t-Verteilung** (engl. **t distribution**) mit  $N - K - 1$  **Freiheitsgraden** (engl. **degrees of freedom**).
- Die **t-Verteilung** schaut einer **Standardnormalverteilung** sehr ähnlich, sie hat aber **fetttere Ränder** (engl. **fatter tails**). Je mehr Freiheitsgrade die Verteilung hat, desto eher kann sie durch eine Normalverteilung approximiert werden.



# Nullhypothese und t-Statistik

Wir spezifizieren folgende **Nullhypothese**:

$$H_0 : \beta_k = 0$$

Nachdem wir alle  $x_j, j \neq k$  berücksichtigt haben, hat  $x_k$  **keinen Einfluss** auf  $y$ .

Wir können diese Nullhypothese mit folgender **Teststatistik** testen:

$$t_{\hat{\beta}_k} = \frac{\hat{\beta}_k - \beta_k}{\text{se}(\hat{\beta}_k)}.$$

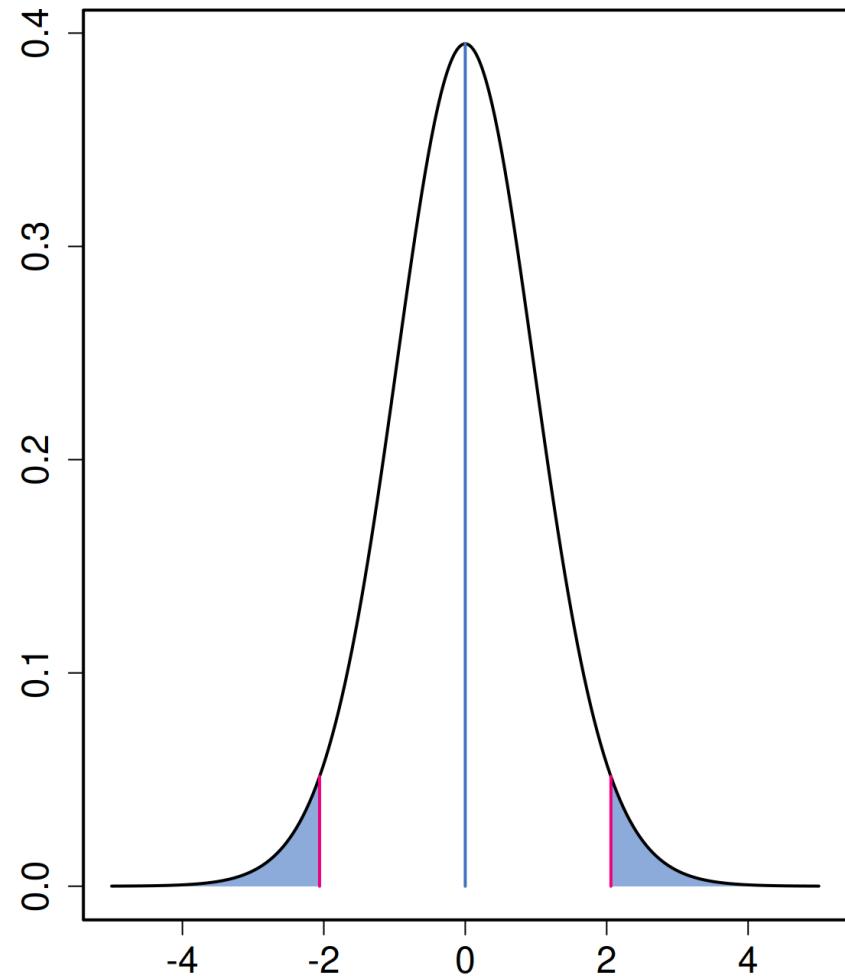
Diese bestimmte **Teststatistik** nennen wir **t-Statistik**.

Unter der Nullhypothese ist  $\beta_k = 0$  und die **t-Statistik** ist

$$t_{\hat{\beta}_k} = \frac{\hat{\beta}_k}{\text{se}(\hat{\beta}_k)}.$$

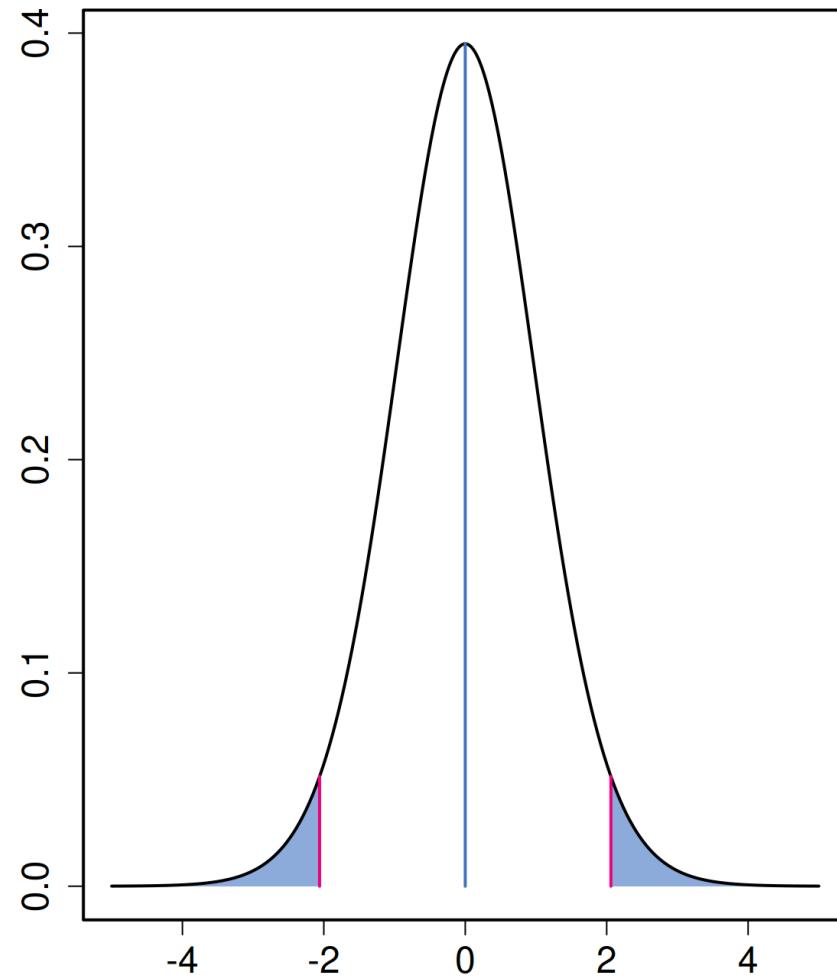
Diese **t-Statistik** ist **t-verteilt** mit Mittelwert 0 und  $N - K - 1$  Freiheitsgraden.

# Zweiseitige Hypothesentests



- Wir testen die Nullhypothese,  $\beta_k = 0$ , gegen eine **zweiseitige Alternative**,  $\beta_k \neq 0$ .
- In der Grafik links ist eine  $t$ -Verteilung mit 25 Freiheitsgraden gezeichnet.
- Wenn die Nullhypothese stimmt, dann sollten die **t-Statistiken der Schätzer, die wir bekommen** so verteilt sein wie in der Grafik links.
- Die Idee ist: Wenn unsere **tatsächliche t-Statistik** so „extrem“ (also so groß oder so klein) ist, dass sie in den blauen **Ablehnbereichen** dieser Verteilung ist, dann sehen wir es als **unwahrscheinlich an**, dass die Nullhypothese stimmt und **verwerfen sie**.

# Wann verwerfen wir die Nullhypothese?



- In der Grafik links hat der **Ablehnbereich**, in denen wir die Nullhypothese verwerfen, insgesamt eine **Fläche von 0.05**. Wir nennen 0.05 das **Signifikanzniveau**.
- Bei einer t-Verteilung mit 25 Freiheitsgraden ergibt das **kritische Werte von -2.06 und 2.06**.
- Wenn der Absolutbetrag der t-Statistik also größer als 2.06 ist, verwerfen wir die Nullhypothese.
- Dass der Schwellenwert hier 2.06 ist, hängt ab von
  - der Anzahl der **Freiheitsgrade** und
  - dem **Signifikanzniveau**.

# Was ist ein Signifikanzniveau?

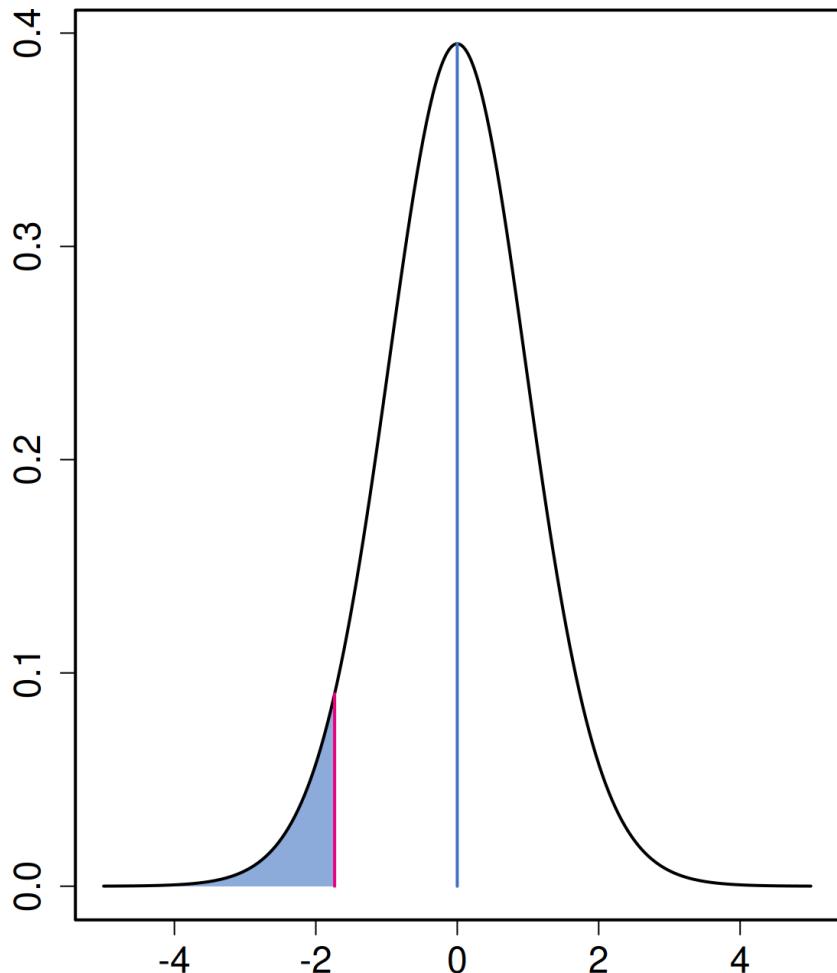
- Wir haben ein **Signifikanzniveau von 0.05** (oder 5%) gewählt. Das bedeutet,
  - dass wir, **wenn die Nullhypothese stimmt**, sie in **5% der Fälle fälschlicherweise verwerfen**;
  - weil es unter der Nullhypothese eine Wahrscheinlichkeit von 5% gibt, dass die t-Statistik betragsmäßig größer als 2.06 ist; wir die Nullhypothese in diesen Fällen aber immer verwerfen.
  - Das nennen wir einen **Typ-1-Fehler** (engl. **type 1 error**), oder auch falsch-positives Ergebnis. Die Wahrscheinlichkeit für so einen Fehler setzen wir selber mit dem Signifikanzniveau.
  - Die Wahrscheinlichkeit für einen **Typ-2-Fehler** (engl. **type 2 error**), ein falsch-negatives Ergebnis (wir verwerfen die Nullhypothese nicht, obwohl sie falsch ist), ist schwieriger zu bestimmen.
- **0.05** ist das am häufigsten verwendete **Signifikanzniveau**; andere häufig verwendete Niveaus sind **0.10, 0.025, 0.01, 0.001, ...**
  - Die **kritischen Werte** für ein bestimmtes Niveau und eine bestimmte Anzahl Freiheitsgrade können wir einer Tabelle oder einem Statistikprogramm entnehmen.

# Speziellere Hypothesen testen

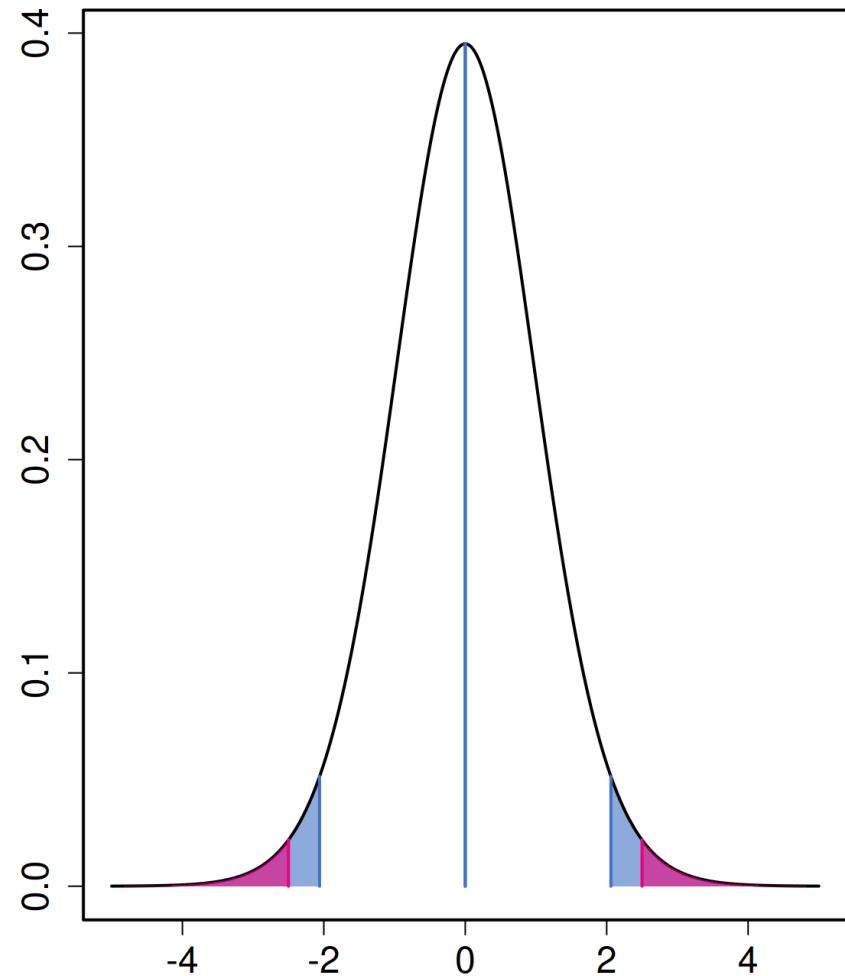
- Wir können auch einen **einseitigen t-Test** durchführen, z.B. mit

$$H_0 : \beta_k \geq 0, \quad H_A : \beta_k < 0.$$

- Bei einem einseitigen Test ist der gesamte Ablehnbereich auf einer Seite, und der kritische Wert für dasselbe Signifikanzniveau und dieselben Freiheitsgrade ist anders.
- Wir können auch sowohl **ein- als auch zweiseitige Tests mit anderen Nullhypotesen** durchführen, z.B.  $H_0 : \beta_k = 1$ . Die Verteilung der t-Statistik ändert sich nicht.



# p-Werte



- Angenommen, wir führen einen Test wie vorher ( $\alpha = 0.05$ ,  $df = 25$ ) durch und erhalten eine t-Statistik von  $t = 2.5$ .
- In der Grafik links ist der Bereich **mit „extremeren“ t-Statistiken als 2.5** (also  $|t| > 2.5$ ) **pink markiert**.
- Die **Wahrscheinlichkeit, eine „extremere“ t-Statistik** als 2.5 zu erhalten, ist **0.019**. Das ist also auch die **Fläche beider pinken Bereiche**.
- Wir nennen diese Größe **p-Wert**. Der p-Wert erleichtert uns die Interpretation: Wir müssen keinen kritischen Wert wissen, sondern nur vergleichen, ob der p-Wert kleiner als das Signifikanzniveau ist. Dann verwerfen wir die Nullhypothese.

# p-Werte und Signifikanz: Interpretation

- Wenn der **p-Wert** kleiner als das von uns gesetzte **Signifikanzniveau** ist, dann **verwerfen wir die Nullhypothese**.
- Angenommen, der zu  $\beta_2$  gehörige p-Wert ist 0.03 und das Signifikanzniveau ist 0.05. Dann können wir **sagen**:
  - $x_2$  ist **statistisch signifikant** (engl. **statistically significant**) bei einem Signifikanzniveau von 0.05 (bzw. 5%).
  - $\beta_2$  ist *statistisch signifikant verschieden von Null* bei einem Signifikanzniveau von 0.05.
  - Wir **verwerfen die Nullhypothese** bei einem Signifikanzniveau von 0.05.
  - Bei einem Signifikanzniveau von 3% wäre der Test indifferent zwischen Verwerfen und Nicht-Verwerfen der Nullhypothese.
- Folgende Dinge sind **falsch** und wir können sie **nicht sagen**:
  - Wir nehmen die Alternativhypothese an.
  - Die Wahrscheinlichkeit, dass die Nullhypothese stimmt, ist 3%.
  - [...] bei einem Signifikanzniveau von 0.95.
  - Wir sind uns zu 97% sicher, dass  $x_2$  einen Einfluss hat.

# Statistische vs. „Ökonomische“ Signifikanz

- Wir haben uns bisher damit beschäftigt, wann eine Variable **statistisch signifikant** ist.
  - Statistische Signifikanz hängt alleine von der zu einem Koeffizienten gehörigen **t-Statistik** ab.
- Ein weiteres, bei der Interpretation wichtiges Konzept ist **ökonomische** bzw. **praktische Signifikanz**.
  - Die Idee ist: Nicht jede Variable, die statistisch signifikant ist, ist auch ein wichtiger Einflussfaktor auf  $y$ .
  - Wir beginnen damit, statistische Signifikanz zu überprüfen.
  - Wenn eine Variable statistisch signifikant ist, können wir als nächstes die (absolute) Größe des Koeffizienten überprüfen.
  - Wenn der Koeffizient sehr nahe bei Null ist, dann übt die Variable wenig Effekt auf  $y$  aus, auch wenn sie statistisch signifikant ist.
  - Eine Variable, die statistisch signifikant ist und einen großen Effekt hat, können wir als „statistisch und ökonomisch signifikant“ interpretieren.
- Bei der **Interpretation** ist es also immer wichtig, auch die **Größe** des Koeffizienten zu beachten.

# Konfidenzintervalle

Unter den **CLM-Annahmen** können wir auch ein **Konfidenzintervall** für einen Parameter der Grundgesamtheit  $\beta_k$  berechnen. Wir besprechen das am Beispiel eines 95 %-Konfidenzintervalls.

- Wir können ein 95 %-Konfidenzintervall so **interpretieren**: Wenn wir wieder und wieder eine Stichprobe ziehen und das Konfidenzintervall berechnen, wird dieses Konfidenzintervall in 95% der Fälle den wahren Parameter abdecken.
- Wir können **nicht** sagen, dass der Parameter (der Grundgesamtheit) in 95% der Fälle in das Konfidenzintervall fällt, da sich das Konfidenzintervall ändert, und **nicht** der Parameter.
- Das 95-Prozent-Konfidenzintervall für einen Parameter  $\beta_k$  ist:

$$\left[ \hat{\beta}_k - c \times \text{se}(\hat{\beta}_k), \quad \hat{\beta}_k + c \times \text{se}(\hat{\beta}_k) \right],$$

wobei  $c$  das 97.5-te Perzentil einer  $t_{N-K-1}$ -Verteilung ist.

Einführung  
Kleine Stichproben  
t-Test  
  
F-Test  
  
Interpretation von Regressionstabellen  
Große Stichproben

# Wie viele Restriktionen wollen wir testen?

Mit dem **t-Test** konnten wir unserem Modell eine einzige **Restriktion** auferlegen, z.B.

$$\beta_1 = 0,$$

und diese Restriktion testen.

Was ist aber, wenn wir **mehrere Restriktionen gemeinsam** testen wollen? Wir können zum Beispiel daran interessiert sein, ob eine bestimmte Menge von unabhängigen Variablen vielleicht als ganzes keinen Effekt auf  $y$  hat:

$$\beta_1 = 0, \beta_2 = 0, \beta_3 = 0.$$

Um solche Restriktionen testen zu können, benötigen wir einen anderen Test, den **F-Test**.

# Mehrere Restriktionen: Hypothesen

$$\beta_1 = 0, \beta_2 = 0, \beta_3 = 0.$$

Die Nullhypothese und Alternativhypothese in diesem Fall sind:

$$H_0 : \beta_1 = 0, \beta_2 = 0, \beta_3 = 0; \quad H_A : H_0 \text{ ist nicht wahr.}$$

- In diesem Fall testen wir **drei Ausschluss-Restriktionen** (engl. **exclusion restrictions**), wir testen also **mehrere Hypothesen** (engl. **multiple hypotheses**) gleichzeitig.
- Da wir die Hypothesen **gleichzeitig** testen, können wir nichts mit den separaten t-Statistiken für die einzelnen Parameter anfangen.
- Wir benötigen also eine **andere Teststatistik**, deren Verteilung wir kennen, um so einen Test durchzuführen.

# Vollständiges und restringiertes Modell

Wir beginnen damit, unser **vollständiges** (unrestringiertes, engl. **unrestricted**) Modell anzuschreiben, zum Beispiel:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + u.$$

Dann wenden wir alle **Restriktionen** an und erhalten das **restringierte Modell** (engl. **restricted model**):

$$y = \beta_0 + \beta_4 x_4 + \beta_5 x_5 + u.$$

Wie können wir diese Modelle **vergleichen**?

- Ein Ansatz: Wir betrachten die **Residuenquadratsummen** (SSR) der beiden Modelle.
- Da die SSR *immer* größer wird, wenn wir Variablen aus dem Modell entfernen, suchen wir eine Teststatistik, die evaluiert, **wie stark der relative Anstieg** der SSR ist, wenn wir unsere Restriktionen anwenden.

# F-Statistik

Eine solche Teststatistik ist

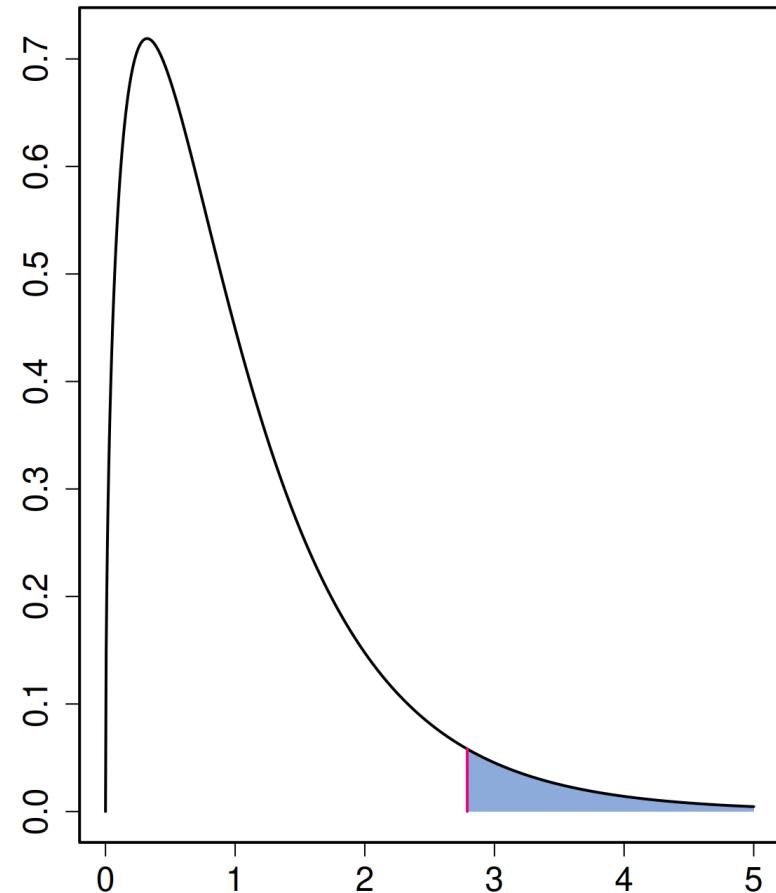
$$F = \frac{(\text{SSR}_r - \text{SSR}_{ur})/q}{\text{SSR}_{ur}/(N - K - 1)},$$

wobei  $q$  die Anzahl der Restriktionen ist, die wir auferlegen.

- Unter den CLM-Annahmen folgt diese Teststatistik, die **F-Statistik**, einer F-Verteilung mit  $q$  Freiheitsgraden im Zähler und  $(N - K - 1)$  Freiheitsgraden im Nenner.
- Die Teststatistik ist **immer größer als Null**.
- Eine alternative Schreibweise der F-Statistik mit  $R^2$  statt der SSR ist

$$F = \frac{(R_{ur}^2 - R_r^2)/q}{(1 - R_{ur}^2)/(N - K - 1)}.$$

# F-Verteilung



- Die Grafik zeigt eine F-Verteilung mit 3 und 50 Freiheitsgraden. Der kritische Wert ist 2.798; wir verwerfen die Nullhypothese, wenn wir eine F-Statistik erhalten, die **größer** als dieser Wert ist (**einseitiger** Test).
- Wenn wir die Nullhypothese nicht verwerfen können, sagen wir, die Variablen sind **gemeinsam nicht signifikant** (engl. **jointly insignificant**).
- Wenn wir die Nullhypothese verwerfen, sagen wir, die Variablen sind **gemeinsam signifikant**.
- Ein F-Test für nur eine Restriktion führt zum gleichen Ergebnis wie ein entsprechender t-Test. Allerdings können mehrere einzeln nicht signifikante Variablen gemeinsam signifikant sein.

# Globale F-Statistik

Wenn wir eine Regression rechnen, berechnet das Statistikprogramm für gewöhnlich eine bestimmte Menge von Restriktionen:

$$H_0 : \beta_1 = 0, \beta_2 = 0, \dots, \beta_K = 0,$$

also, dass **alle unabhängigen Variablen gemeinsam keinen Beitrag leisten, um  $y$  zu erklären.**

Die **F-Statistik** für diesen Fall kann geschrieben werden als

$$F = \frac{R^2/K}{(1 - R^2)/(N - K - 1)}.$$

Sowohl bei dieser „globalen“ als auch bei allen anderen F-Statistiken wird von Statistikprogrammen ein **p-Wert** ausgegeben, der wie bei t-Statistiken die Interpretation erleichtert.

Kleine Stichproben

t-Test

F-Test

# Interpretation von Regressionstabellen

Große Stichproben

# Huh, ein Baseball-Datensatz



Wir verwenden den Baseball-Datensatz aus dem Wooldridge-Buch, um uns das Ganze an einem praktischen Beispiel anzusehen.

R Code

[⟳ Start Over](#)

[▷ Run Code](#)

```
1 # Pakete laden
2 library(wooldridge) # Enthält den Datensatz
3 library(dplyr)
4 library(car) # Später für F-Test
5
6 # Daten laden
7 data("mlb1") # Baseball-Daten
8
9 # Nur die Variablen behalten, die uns interessieren
10 mlb1 <- mlb1 |>
11   select(salary, years, gamesyr, bavg, hrunsyr, rbisyr)
```

# Wir schätzen fleißig Regressionen

R Code

[⟳ Start Over](#)

[▷ Run Code](#)

```
1 lm(log(salary) ~ years + gamesyr + bavg + hr)
2 summary()
```

R Code

[⟳ Start Over](#)

[▷ Run Code](#)

```
1 lm(log(salary) ~ years + gamesyr, data = mlb)
2 summary()
```

# Signifikant oder nicht signifikant, das ist hier die Frage

R Code [Start Over](#) [Run Code](#)

```
1 model <- lm(log(salary) ~ years + gamesyr + bavg + hrunsy
2
3 linearHypothesis(model, c("bavg = 0", "hrunsyr = 0", "rbisyr = 0"))
```

- **Keine** der drei Variablen **bavg**, **hrunsyr**, und **rbisyr** war für sich selbst genommen **signifikant**.
- Wenn wir aber testen, ob die drei Variablen **gemeinsam signifikant** sind, können wir die Nullhypothese verwerfen.
- Der p-Wert der F-Statistik für das gesamte Regressionsmodell war bei beiden Modellen **sehr klein**.

t-Test

F-Test

Interpretation von Regressionstabellen

Große Stichproben

# Was ist eine große Stichprobe?

- Alle Eigenschaften des OLS-Schätzers, die wir bisher besprochen haben, treffen in allen **endlichen Stichproben** zu (engl. **finite sample properties**), egal, wie groß oder klein  $N$  ist.
  - Dazu gehören die **Unverzerrtheit** des OLS-Schätzers, das **Gauß-Markov-Theorem**, etc.
  - Dazu gehört auch alles, was wir über die Stichprobenverteilung der OLS-Schätzer, t- und F-Tests besprochen haben ... **solange wir MLR.6 annehmen**.
- Zusätzlich zu diesen Eigenschaften hat OLS bestimmte **Eigenschaften in großen Stichproben** (engl. **large sample properties**).
  - Damit meinen wir Eigenschaften, die auftreten, wenn  $N$  **gegen unendlich geht**, also nicht Eigenschaften, die für eine bestimmte Stichprobengröße  $N$  (oder gar alle möglichen  $N$ ) zutreffen.
  - Gewisse Eigenschaften treffen in großen Stichproben auch zu, wenn bestimmte Annahmen nicht erfüllt sind.

# Was passiert ohne Annahme MLR.6?

- **Ohne Annahme MLR.6** muss die t-Statistik keiner t-Verteilung folgen, und die F-Statistik muss keiner F-Verteilung folgen. Wir können also Hypothesen über die Parameter nicht wie bisher testen.
- Wir haben aber auch darüber gesprochen, dass MLR.6 **unrealistisch** ist. MLR.6 impliziert auch, dass  $y | \boldsymbol{x}$  normalverteilt ist. Für bestimmte  $y$ -Variablen macht das offensichtlich keinen Sinn.
- Praktischerweise kann mithilfe des Zentralen Grenzwertsatzes für **große Stichproben** folgendes gezeigt werden:

Unter Annahmen **MLR.1 bis MLR.5** ist die t-Statistik **asymptotisch normalverteilt**:

$$\frac{\hat{\beta}_k - \beta_k}{\text{se}(\hat{\beta}_k)} \xrightarrow{d} N(0, 1) \quad \text{bzw.} \quad \frac{\hat{\beta}_k - \beta_k}{\text{se}(\hat{\beta}_k)} \xrightarrow{d} t_{N-K-1}.$$

# Was passiert ohne Annahme MLR.6?

Unter Annahmen **MLR.1 bis MLR.5** ist die t-Statistik **asymptotisch normalverteilt**:

$$\frac{\hat{\beta}_k - \beta_k}{\text{se}(\hat{\beta}_k)} \xrightarrow{d} N(0, 1) \quad \text{bzw.} \quad \frac{\hat{\beta}_k - \beta_k}{\text{se}(\hat{\beta}_k)} \xrightarrow{d} t_{N-K-1}.$$

- Da die t-Verteilung für große Freiheitsgrade in Verteilung gegen eine Standardnormalverteilung konvergiert, können wir sowohl den linken als auch den rechten Ausdruck verwenden.
- Das bedeutet, dass wir die **t-Statistik** genau so verwenden können wie mit MLR.6, sofern unsere Stichprobe ausreichend groß ist.
- Die asymptotische Normalität der OLS-Schätzer impliziert auch, dass die **F-Statistik** in großen Stichproben asymptotisch F-verteilt ist.

# LM-Statistik

Der **Lagrange-Multiplier-Test (LM-Test)** ist eine Alternative zum F-Test in großen Stichproben.

- Die LM-Statistik ist unter den Annahmen MLR.1 bis MLR.5 asymptotisch  $\chi_q^2$ -verteilt (die Verteilung in kleinen Stichproben ist unbekannt).
- Wir erhalten die LM-Statistik wie folgt:
  - (1) Wir schätzen nur das restringierte Modell.
  - (2) Wir nehmen die Residuen aus dieser Regression und regressieren sie wiederum auf alle  $K$  unabhängigen Variablen des *vollständigen* Modells.
  - (3) Wir berechnen die LM-Statistik als  $LM = NR^2$ , wobei  $R^2$  das  $R^2$  aus der Regression aus Schritt (2) ist.
- Die Idee ist also: Können die zusätzlichen erklärenden Variablen die **Residuen** aus dem restringierten Modell **erklären**?
- **LM-Test** und **F-Test** führen selten zu unterschiedlichen Resultaten.

# Literatur

Wooldridge, J. M. (2020). *Introductory econometrics : a modern approach* (Seventh edition, S. xxii, 826 Seiten). Cengage. <https://permalink.obvsg.at/wuw/AC15200792>